

Άσκηση 3

Θέματα Όρασης Υπολογιστών

Περιεχόμενα

Διαδικασία 1	2
Διαδικασία 2.....	3
Διαδικασία 3.....	4
Διαδικασία 4.....	4
Διαδικασία 5.....	6
Διαδικασία 6.....	12
Διαδικασία 7.....	15
Διαδικασία 8.....	17
Διαδικασία 9.....	20

Ο κώδικας μπορεί να βρεθεί εδώ:

<https://github.com/GrigorisTzortzakos/Computer-Vision/tree/main/Exercise%203>

Διαδικασία 1

1. Ανίχνευση Ακροτάτων στον Χώρο Κλίμακας (Scale-Space Extrema Detection)
Στον κώδικα, το πρώτο στάδιο ξεκινά αμέσως μετά την αρχικοποίηση της εικόνας (μεταβλητές row, column, img, κ.λπ.). Έπειτα, στο τμήμα κώδικα που δημιουργεί τις εικόνες DoG (διαφορές Γκαουσιανών) για διάφορες κλίμακες (με χρήση της συνάρτησης `fspecial('gaussian',...)` και των πράξεων συνέλιξης `conv2`), δημιουργείται η πυραμίδα του χώρου κλίμακας. Εκεί, βλέπουμε πως ο παράγοντας κλίμακας ενημερώνεται διαδοχικά, ενώ οι τιμές της κάθε κλίμακας αποθηκεύονται στην κυψέλη $D(D\{i\})$, όπου το i δείχνει διαφορετικές οκτάβες). Με αυτόν τον τρόπο υλοποιείται η παραγωγή των εικόνων και στη συνέχεια η υπολογισμένη διαφορά τους.

2. Ανίχνευση Τοπικών Ακροτάτων (Keypoint Localisation / Finding Local Extrema)
Αμέσως μετά τη δημιουργία των DoG εικόνων, ο κώδικας στο τμήμα που ξεκινά με το σχόλιο `%% Keypoint Localisation` αναζητά τα τοπικά ακρότατα. Χρησιμοποιεί μια διαδοχή από loops για να συγκρίνει κάθε pixel με τους 26 γείτονές του (8 στην ίδια κλίμακα και $9 + 9$ στις προηγούμενες και επόμενες κλίμακες). Μέσα από αυτές τις συγκρίσεις, επισημαίνονται ως *candidate extrema* εκείνα τα σημεία που είναι είτε μεγαλύτερα είτε μικρότερα από όλους τους γείτονες τους. Αυτή η διαδικασία αντιστοιχεί στο θεωρητικό βήμα στο οποίο ψάχνουμε για μέγιστα και ελάχιστα στο χώρο κλίμακας.

3. Ακριβής Εύρεση των Σημείων Κλειδιών (Refinement / Filtering Out Low Contrast Points)
Στον κώδικα υπάρχει μια διαδικασία φιλτραρίσματος (με τη βοήθεια παραγόντων `threshold`, ελέγχου της αντίθεσης και του λόγου καμπυλότητας `R_threshold` για τον αποκλεισμό `edge responses`). Εκεί, απορρίπτονται τα σημεία που είτε έχουν χαμηλή αντίθεση είτε είναι ασταθή λόγω θορύβου ή επειδή βρίσκονται σε επίπεδο που μοιάζει με ακμή. Αυτό σημαίνει ότι χρησιμοποιούμε κριτήρια τύπου Hessian για να υπολογίσουμε αν το σημείο βρίσκεται σε μια δυνατή γωνία ή σε *edge-like* περιοχή, οπότε το απορρίπτουμε. Όλες αυτές οι επιπλέον συνθήκες ελέγχου μεγάλων και μικρών τιμών και η μέτρηση δευτέρας παραγώγου για την καμπυλότητα καταλήγουν στο να κρατηθούν μόνο τα σωστά σημεία κλειδιά (*stable keypoints*). Στο κομμάτι του κώδικα που ξεκινάει με το σχόλιο `%% accurate keypoint localization` και συνεχίζει με τις μεταβλητές `threshold`, `r`, `Dxx`, `Dyy`, `Dxy`, μπορούμε να δούμε πώς εφαρμόζεται αυτός ο έλεγχος ακμών (*edge response check*) καθώς και ο έλεγχος χαμηλής αντίθεσης.

4. Διόρθωση Κατεύθυνσης και Περιγραφέας (Orientation Assignment & Keypoint Descriptor)

Αφού ολοκληρωθεί το ξεκαθάρισμα των σημείων, περνάμε στη φάση της απόδοσης προσανατολισμού (*orientation assignment*), την οποία βλέπουμε με το σχόλιο `%% Orientation Assignment(Multiple orientations assignment)`. Εδώ,

υπολογίζεται η κλίση (magnitude) και η γωνία (orientation) των γειτονικών pixel, κατασκευάζεται το ιστογράφημα προσανατολισμού (με 36 bins από 0 έως 360 μοίρες), και επιλέγονται οι κορυφές του ιστογράμματος που υπερβαίνουν το 80% του παγκόσμιου μεγίστου για την εκχώρηση ενός ή και περισσότερων προσανατολισμών. Στη συνέχεια, ακολουθεί η δημιουργία του τοπικού περιγραφέα (descriptor) στο τμήμα `%% keypoint descriptor`. Εκεί χωρίζεται η γειτονιά κάθε σημείου κλειδιού σε υποπεριοχές (π.χ. 4x4), υπολογίζονται οι επιμέρους τοπικές κλίσεις και δημιουργούνται ιστογράμματα προσανατολισμού 8 κατηγοριών για καθεμία από αυτές τις υποπεριοχές. Στο τέλος, ο κώδικας κανονικοποιεί αυτό το διάνυσμα ώστε να περιορίζει την επίδραση αλλαγών φωτεινότητας και αντίθεσης.

Διαδικασία 2

Στο πρώτο στάδιο που είναι η Ανίχνευση Ακροτάτων στον Χώρο Κλίμακας, δημιουργούνται διαδοχικές εκδόσεις της εικόνας με διαφορετική κλίμακα θόλωσης μέσω συνέλιξης με πυρήνες gauss. Στη συνέχεια, από αυτές τις εικόνες (μία σειρά από επίπεδα σε κάθε οκτάβα), προκύπτουν οι εικόνες διαφοράς Γκαουσιανών αφαιρώντας μεταξύ τους ζεύγη γειτονικών θολωμένων εκδόσεων. Το αποτέλεσμα είναι ένα σύνολο από εικόνες, κάθε μία από τις οποίες αναδεικνύει έντονες μεταβολές στη φωτεινότητα και άρα πιθανά σημεία ενδιαφέροντος.

Αμέσως μετά, ακολουθεί το στάδιο Ανίχνευσης Τοπικών Ακροτάτων. Εδώ, εξετάζουμε κάθε pixel των DoG εικόνων συγκρίνοντάς το με τους γείτονές του, όχι μόνο εντός της ίδιας κλίμακας, αλλά και στην προηγούμενη και στην επόμενη. Έτσι, κάθε υποψήφιο pixel συγκρίνεται με 26 γειτονικά του για να διαπιστωθεί αν είναι τοπικό μέγιστο ή τοπικό ελάχιστο. Τα σημεία που βρίσκονται είτε πάνω από όλους τους γείτονές τους είτε κάτω από όλους διατηρούνται ως candidate keypoints.

Στο τρίτο στάδιο, Ακριβής Εύρεση των Σημείων Κλειδιών, θέτουμε πρόσθετα κριτήρια ώστε να απορρίψουμε σημεία που μπορεί να εμφανίζονται λόγω θορύβου, χαμηλής αντίθεσης ή αν βρίσκονται πάνω σε έντονη ακμή. Σε αυτό το βήμα, εφαρμόζεται πρώτα ένα όριο (threshold) στη τιμή της συνάρτησης DoG, ώστε να απομακρυνθούν τα σημεία με πολύ χαμηλή τιμή. Έπειτα, εξετάζουμε τις δευτερόπαράγωγους (D_{xx} , D_{yy} , D_{xy}), υπολογίζουμε την καμπυλότητα (με κριτήρια που θυμίζουν τη μορφή του Hessian) και εντοπίζουμε τα σημεία που παρουσιάζουν μεγάλο λόγο καμπυλότητας σε μόνο μία διεύθυνση. Αυτά τα σημεία, που αντιστοιχούν σε edge responses, αφαιρούνται από το σύνολο. Έτσι, απομένουν τα πραγματικά σταθερά σημεία κλειδιά με επαρκή αντίθεση και χωρίς ισχυρό προσανατολισμό σε μία μόνο διεύθυνση.

Τέλος, στο τέταρτο στάδιο, που περιλαμβάνει τη Διόρθωση Κατεύθυνσης και τον descriptor, υπολογίζεται η κλίση και η κατεύθυνση της φωτεινότητας γύρω από κάθε σημείο κλειδί, σε μια κλίμακα σχετική με το ίδιο το σημείο. Χρησιμοποιείται ένα τοπικό ιστογράφημα κατευθύνσεων, εντοπίζονται οι κορυφές του και η κύρια ή οι κύριες κατευθύνσεις (για την αντιμετώπιση

πιθανών πολλαπλών τοπικών μεγίστων). Με βάση αυτή την κατεύθυνση ή και περισσότερες, περιστρέφουμε τη γειτονιά του σημείου και υπολογίζουμε έναν περιγραφέα, ο οποίος συνήθως οργανώνεται ως ένα σύνολο τοπικών ιστογραμμάτων κλίσης. Το πιο διαδεδομένο σχήμα περιγράφει τη γειτονιά ως 4×4 υποπεριοχές, καθεμία με 8 bins προσανατολισμού, δημιουργώντας έτσι ένα διάνυσμα 128 διαστάσεων για κάθε σημείο κλειδί. Με την κανονικοποίηση αυτού του διανύσματος, επιτυγχάνεται ανθεκτικότητα σε αλλαγές φωτισμού, περιστροφής και μικρής κλίμακας παραμορφώσεις.

Διαδικασία 3

Στην θεωρία, ο αλγόριθμος δημιουργεί οκτάβες του χώρου κλίμακας, όπου καθεμία ορίζεται από ένα εύρος κλιμάκων που ξεκινά από μια τιμή και φτάνει μέχρι τη διπλάσια τιμή. Στο διάστημα αυτό εισάγονται κάποια ενδιάμεσα levels θόλωσης, ώστε να προκύψουν επαρκείς κλίμακες για την ανίχνευση χαρακτηριστικών σημείων. Ουσιαστικά, μέσα σε μια οκτάβα, ο αλγόριθμος παράγει μια ακολουθία από Γκαουσιανές εκδοχές της εικόνας, η καθεμία εκ των οποίων έχει αυξανόμενη τυπική απόκλιση. Η παράμετρος που ελέγχει τον αριθμό των επιπέδων σε κάθε οκτάβα είναι το πεδίο level, το οποίο έχει οριστεί ως 3 (level = 3;). Αυτό σημαίνει ότι για κάθε οκτάβα παράγονται τρεις επιπλέον θέσεις θόλωσης. Όταν ολοκληρώσουμε αυτά τα τρία επίπεδα, κατεβάζουμε την ανάλυση της εικόνας στο μισό (downsampling) και εισερχόμαστε στην επόμενη οκτάβα με ένα νέο ξεκίνημα κλιμάκων.

Διαδικασία 4

1. Χρήση ανάπτυξης Taylor δεύτερης ή τρίτης τάξης
Μία ευρέως χρησιμοποιούμενη τεχνική είναι να προσεγγίσουμε τοπικά τη συνάρτηση γύρω από το υποψήφιο σημείο keypoint με μια πολυωνυμική ανάπτυξη Taylor, συνήθως δεύτερης ή τρίτης τάξης. Με τον τρόπο αυτό, μπορούμε να βρούμε τη θέση του πραγματικού ακροτάτου με συνεχή τρόπο (στην πράξη, να λύσουμε για τις παραγώγους της συνάρτησης και να εκτιμήσουμε πού μηδενίζονται). Το βασικό πλεονέκτημα της μεθόδου αυτής είναι ότι προσφέρει έναν μαθηματικά σαφή τρόπο υπολογισμού του ακροτάτου, λαμβάνοντας υπόψη τόσο τις τιμές της συνάρτησης όσο και τις πρώτες/δεύτερες παραγώγους της σε μια μικρή περιοχή. Έτσι, η ακρίβεια μπορεί να βελτιωθεί αισθητά σε σχέση με την απλή εύρεση ακροτάτου στο πλησιέστερο pixel. Μειονέκτημα αποτελεί το γεγονός ότι απαιτείται υπολογισμός και αποθήκευση περισσότερων τιμών (συμπεριλαμβανομένων των παραγώγων), γεγονός που αυξάνει το υπολογιστικό κόστος, ειδικά σε μεγάλες εικόνες ή σε εφαρμογές πραγματικού χρόνου. Επίσης, η ακρίβεια της προσέγγισης εξαρτάται από την υπόθεση ότι το πραγματικό προφίλ των τιμών γύρω από το keypoint μπορεί όντως να προσεγγιστεί επαρκώς με μια ανάπτυξη Taylor μέχρι δεύτερης ή τρίτης τάξης.

2. Παρεμβολή με παράθυρο παρόμοιο με παραβολική ή πολυωνυμική προσέγγιση

Μια ακόμη μέθοδος είναι η προσπάθεια εφαρμογής παραβολικής ή γενικότερα πολυωνυμικής παρεμβολής (interpolation) γύρω από το υποψήφιο ακρότατο. Αντί να χρησιμοποιήσουμε ρητά τις παραγώγους, μπορούμε να έχουμε ένα μικρό παράθυρο δεδομένων γύρω από το σημείο (π.χ. οι τιμές DoG σε $3 \times 3 \times 3$ περιοχή) και να εφαρμόσουμε κάποια μορφή πολυωνυμικής προσαρμογής (curve fitting) για να εντοπίσουμε τη μέγιστη ή ελάχιστη τιμή. Με αυτή τη μέθοδο, αξιοποιούνται με γραμμικό ή μη γραμμικό τρόπο οι τιμές των γειτονικών *pixel*, οπότε μπορούμε να λάβουμε μια ακριβέστερη εκτίμηση της θέσης του ακροτάτου. Πλεονέκτημα εδώ είναι ότι η υλοποίηση μπορεί να είναι πιο ευέλικτη, επιτρέποντας διάφορα σχήματα παρεμβολής (π.χ. bicubic interpolation). Ωστόσο, η πολυπλοκότητα μπορεί να αυξηθεί και εάν η συνάρτηση δεν προσεγγίζεται καλά από το επιλεγμένο πολυώνυμο, ενδέχεται να έχουμε σφάλματα εκτίμησης. Επίσης, απαιτείται προσεκτική ρύθμιση του μεγέθους του παραθύρου (window size) για να αποφύγουμε θολούς υπολογισμούς.

3. Μέθοδος κλίσης/σφαλμάτων σε συνδυασμό με επαναληπτικό βήμα (gradient-based / iterative refinement)

Μια άλλη μέθοδος είναι η χρήση επαναληπτικών αλγορίθμων βελτιστοποίησης (π.χ. gradient descent / Newton-Raphson) όπου αρχίζοντας από την αρχική εκτίμηση του keypoint (το κέντρο του *pixel* που εντοπίστηκε ως πιθανό μέγιστο/ελάχιστο), κάνουμε βήματα προς τη διεύθυνση της κλίσης έως ότου βρεθούμε σε πραγματικό τοπικό ακρότατο. Αυτή η διαδικασία μπορεί να εφαρμοστεί τόσο στον χώρο των συντεταγμένων (x,y) όσο και στον άξονα της κλίμακας, ουσιαστικά αντιμετωπίζοντας την τρισδιάστατη ή τετραδιάστατη συνάρτηση ως μια επιφάνεια που αναζητούμε το ακρότατο. Το μεγάλο πλεονέκτημα είναι ότι επιτυγχάνεται ακρίβεια εξαρτώμενη από τον αριθμό των επαναληπτικών βημάτων και την ποιότητα του σήματος. Επίσης, σε θορυβώδη δεδομένα ή σε εικόνες όπου η προσέγγιση Taylor είναι ανεπαρκής, αυτή η προσαρμοστική μέθοδος μπορεί να είναι πιο ανθεκτική. Το μειονέκτημα είναι η αυξημένη υπολογιστική πολυπλοκότητα, αφού κάθε σημείο απαιτεί επαναληπτικά βήματα, καθώς και ο κίνδυνος σύγκλισης σε λάθος τοπικό ακρότατο αν η αρχική εκτίμηση δεν είναι αρκετά κοντά στο πραγματικό μέγιστο.

4. Χρήση κεντροβαρικών ή σταθμισμένων μεθόδων (centroid / weighted centroid approach)


Σε ορισμένες περιπτώσεις, μπορούν να εφαρμοστούν πιο απλές μέθοδοι κεντροβαρικού τύπου, δηλαδή λαμβάνουμε την ένταση ή κάποια άλλη μέτρηση στον χώρο των *pixel* κοντά στο ακρότατο και υπολογίζουμε το γεωμετρικό κέντρο βάρους (centroid). Αυτή η προσέγγιση βασίζεται στην ιδέα ότι, αν ένα σημείο είναι πράγματι τοπικό ακρότατο, οι τιμές των γειτονικών *pixel* γύρω του θα είναι ελαφρώς μικρότερες ή μεγαλύτερες και μπορούμε να βρούμε πιο ομαλά το πραγματικό κέντρο. Το πλεονέκτημα είναι η ευκολία και η ταχύτητα

υπολογισμού, ενώ το μειονέκτημα είναι ότι λειτουργεί καλά μόνο όταν το προφίλ της έντασης είναι σχετικά συμμετρικό γύρω από το πραγματικό ακρότατο. Σε εικόνες με θόρυβο ή ανισορροπία στη φωτεινότητα, η μέθοδος μπορεί να αποδώσει αποτελέσματα μετατοπισμένα ή να μην συγκλίνει σε ορθή θέση.

Διαδικασία 5

Αντί να τρέχουμε τον Sift για καθεμιά από τις εικόνες ξεχωριστά, δημιουργούμε ένα script που το κάνει αυτόματα. Το μόνο που πρέπει να προσέξουμε είναι ότι ο Sift κάθε φορά κάνει clear, άρα δεν θα διαβάζει την επόμενη εικόνα. Τότε, απλά αποθηκεύουμε την εικόνα σε μεταβλητή και την περνάμε κάθε φορά στο cameraman.tif ως όρισμα, άρα τρέχει αυτόματα και για τις 5 εικόνες.

Παρακάτω παρουσιάζουμε τις εικόνες που χρησιμοποιούνται για ορίσματα στο Sift:



Εικόνα 1:


Με την εκτέλεση του κώδικα, παράγονται πρώτα οι εικόνες του χώρου κλίμακας (Gaussian blurred images) και έπειτα οι αντίστοιχες εικόνες διαφοράς Γκαουσιανών. Η οπτική τους επιβεβαιώνει ότι σε περιοχές με υψηλή συχνότητα φωτεινότητας εμφανίζονται έντονες μεταβολές, ενώ σε λεία σημεία ή περιοχές με σχετικά ομοιόμορφη φωτεινότητα (π.χ. καθαρός ουρανός) οι διαφορές είναι λιγότερες. Στην εικόνα μας, το φύλλωμα, τα άνθη και τα όρια


μεταξύ λουλουδιών και ουρανού αναδεικνύονται στις DoG εικόνες ως φωτεινότερα ή σκοτεινότερα σχήματα.

Το δεύτερο στάδιο του SIFT (εντοπισμός τοπικών ακροτάτων) εντοπίζει μεγάλο πλήθος σημείων στα φύλλα και στα άνθη, καθώς εκεί υπάρχουν πολυάριθμες μικρές μεταβολές φωτεινότητας. Αντιθέτως, σε ομοιόμορφα τμήματα, όπως ο ουρανός ή η πέτρινη επιφάνεια με σχετικά απαλές μεταβολές, βρίσκουμε σαφώς λιγότερα keypoints. Από την εκτέλεση του κώδικα παρατηρήθηκε ότι πλήθος σημείων συγκεντρώνονται περιμετρικά στα όρια των πετάλων και των φύλλων που δημιουργούν υψηλή αντίθεση.

Έπειτα, εφαρμόζεται η διαδικασία φιλτραρίσματος (απορρίπτει σημεία χαμηλής αντίθεσης ή όσα εντοπίζονται σε έντονες ακμές που δεν προσφέρουν επαρκή πληροφορία). Ακόμα και μετά το φιλτράρισμα, η τελική εικόνα παρουσιάζει αρκετά μεγάλο αριθμό σημείων, κυρίως γύρω από τις περιοχές με κλαδιά, μικρά φύλλα και τα όρια των λουλουδιών.

Το τελικό σύνολο keypoints απεικονίζεται σε χρωματικές ενδείξεις (πράσινες και μπλε). Φαίνεται ότι πάρα πολλά σημεία βρίσκονται στο άνω μέρος της εικόνας, στα σημεία όπου οι αποχρώσεις των λουλουδιών και των φύλλων διακρίνονται καθαρά από το φόντο. Αυτό είναι αναμενόμενο, δεδομένου ότι ο SIFT ευνοεί περιοχές με κλίσεις και υψηλό ποσοστό χωρικής πληροφορίας. Επίσης, κάποια βασικά keypoints εντοπίζονται κατά μήκος των ακμών της πέτρινης επιφάνειας, καθώς οι γραμμές δημιουργούν μικρά μοτίβα αντίθεσης.







Εικόνα 2:

Όπως και στην προηγούμενη περίπτωση, το πρώτο στάδιο δημιουργεί διάφορες εκδόσεις της εικόνας θολωμένες με πυρήνες Gauss. Στη συνέχεια υπολογίζονται οι DoG και παρατηρούμε ότι τα όρια των αντικειμένων (π.χ. περίγραμμα φοινίκων, άκρες κτιρίων, κολωνάκια και σχηματισμός πεζοδρομίου) αναδεικνύονται έντονα. Αντίθετα, οι πιο ομαλές περιοχές, όπως ο ουρανός ή το ομοιόμορφο τμήμα των τοίχων, εμφανίζουν λιγότερη λεπτομέρεια.

Στη συνέχεια, ο αλγόριθμος ψάχνει για τοπικά μέγιστα και ελάχιστα στις DoG εικόνες. Μπορούμε να δούμε ότι εντοπίζεται ικανός αριθμός keypoint σε περιοχές με έντονες γωνίες και μεταβολές φωτεινότητας. Για παράδειγμα, αυτά παρατηρούνται στον κορμό και στα φύλλα των φοινίκων, γύρω από τις πέτρινες επιφάνειες (τοίχοι, κολωνάκια), καθώς και στις γραμμές των μπαλκονιών και στα παράθυρα του κτιρίου.

Όπως είναι φυσικό, το φιλτράρισμα αφαιρεί σημεία που δεν ξεχωρίζουν αρκετά από το φόντο (χαμηλή αντίθεση) ή βρίσκονται σε έντονες ακμές χωρίς διακριτά χαρακτηριστικά. Στο αποτέλεσμα βλέπουμε ότι η τελική κατανομή των σημείων επιβεβαιώνει πως οι περισσότεροι ανιχνεύσιμοι κόμβοι πληροφορίας εντοπίζονται σε γωνίες και μεταβάσεις φωτεινότητας. Μέσα στα ομαλότερα τμήματα του τοίχου ή στον καθαρό ουρανό, εντοπίζονται ελάχιστα keypoints, κάτι που αναδεικνύει την έλλειψη δομής σε αυτές τις περιοχές.

Βλέπουμε ότι αρκετές λεπτομέρειες εμφανίζονται κατά μήκος της διαδρομής του δρόμου (στην κάτω πλευρά της εικόνας, κοντά στο πεζοδρόμιο), ενώ ακόμη περισσότερα σημεία παρατηρούνται γύρω από τους φοίνικες, εξαιτίας των φύλλων τους. Επίσης, οι πέτρινες επιφάνειες και τα διαχωριστικά στους τοίχους δημιουργούν αρκετές μεταβολές έντασης. Συνολικά, η εικόνα διαθέτει αρκετές τεχνητές γωνίες (κτίριο, πεζοδρόμιο) και φυσικά μοτίβα (κορμοί και φύλλα φοινίκων) που εντοπίζει ο αλγόριθμος.



Εικόνα 3:



Όπως και στις προηγούμενες περιπτώσεις, δημιουργούνται διαδοχικές εκδοχές της αρχικής εικόνας με διαφορετικές Γκαουσιανές θολώσεις. Παρατηρείται ότι οι έντονες μεταβολές έντασης εμφανίζονται γύρω από τα όρια των φύλλων, τους κορμούς των δέντρων και τα σχήματα των κλαδιών. Αντίθετα, σε πιο ομαλές περιοχές του γκαζόν και του ουρανού, η αντίθεση είναι μικρότερη, οπότε και οι εικόνες παρουσιάζουν λιγότερο εμφανή μοτίβα.

Ο SIFT ελέγχει τα DoG δεδομένα για τοπικά ακρότατα. Στην εικόνα παρατηρείται μεγάλη συγκέντρωση από σημεία κλειδιά (keypoints) εκεί όπου τα φύλλα έχουν έντονες κλίσεις φωτεινότητας, κάτι ιδιαίτερα εμφανές στα μακρόστενα, μυτερά φύλλα των φυτών. Επιπλέον, γύρω από τους κορμούς και στις διακλαδώσεις εμφανίζονται έντονες μεταβάσεις σκιάς και φωτός, που επίσης οδηγούν σε πλήθος σημείων. Η πυκνότητα των keypoints είναι αυξημένη και σε άλλες δομές με αρκετή λεπτομέρεια, όπως γύρω από την κολόνα.

Κατόπιν, εφαρμόζεται η διαδικασία φιλτραρίσματος των υποψήφιων σημείων χαμηλής αντίθεσης και όσων βρίσκονται πάνω σε έντονες, εκτενείς ακμές.

Ωστόσο, ακόμα και μετά το φιλτράρισμα, η τελική εικόνα δείχνει σχετικά πολλά keypoints, ιδιαίτερα στις περιοχές όπου τα φύλλα των φυτών αλληλεπικαλύπτονται και δημιουργούν μικρές, περίπλοκες υφές (textures).

Η κατανομή των keypoints επιβεβαιώνει πως οι περισσότερες ενδιαφέρουσες μεταβολές βρίσκονται στα φύλλα, τα κλαδιά και τους κορμούς. Παρατηρούμε επίσης αρκετά roints στα σημεία επαφής του κορμού με το έδαφος, όπου οι υφές του γρασιδιού, της σκιάς και των πεσμένων φύλλων δημιουργούν επιπλέον μεταβολές φωτεινότητας. Πιο ομαλές περιοχές του φόντου, όπως το καθαρό μέρος του ουρανού (στο πάνω τμήμα της εικόνας) και οι επίπεδες περιοχές χόρτου, εμφανίζουν μικρότερη πυκνότητα χαρακτηριστικών.






Εικόνα 4:

Κάνουμε πάλι το αρχικό βήμα όπως στις προηγούμενες εικόνες και διακρίνονται έντονες μεταβολές γύρω από τα όρια των βιβλίων, των χαρτιών και των διάφορων αντικειμένων πάνω στο γραφείο (ποτήρια, στυλό κ.λπ.).

Αντίθετα, σε τμήματα με ομοιόμορφη υφή, όπως το χαλί (αν και έχει κάποια μοτίβα), οι μεταβολές εμφανίζονται σχετικά πιο ήπιες.

Παρακάτω, παρατηρούμε μεγάλο αριθμό keypoints σε περιοχές όπου συναντώνται γωνίες και έντονες μεταβάσεις φωτεινότητας, π.χ. κατά μήκος των σελίδων των βιβλίων, στις άκρες των τετραδίων, γύρω από τα αντικείμενα γραφείου αλλά και στις μεταβάσεις ανάμεσα στο τραπέζι και τα υπόλοιπα αντικείμενα.




Όπως σε όλες τις προηγούμενες περιπτώσεις, στη συνέχεια απορρίπτονται σημεία με χαμηλή αντίθεση ή όσα βρίσκονται πάνω σε έντονες ακμές που δεν προσφέρουν διακριτά χαρακτηριστικά. Ωστόσο, το σύνολο των τελικών keypoints παραμένει αρκετά πλούσιο, κάτι που εξηγείται από τη μεγάλη ποικιλία αντικειμένων και τις πολλές αιχμηρές ακμές (άκρα βιβλίων, στυλό, κουτιά, κύπελλα).



Εικόνα 5:

Στις DoG τονίζονται σημαντικά οι ακμές και οι χωρικές μεταβολές, με αποτέλεσμα τα όρια ανάμεσα στο πεζοδρόμιο και τα φυτά , να αποτυπώνονται φωτεινότερα ή σκουρότερα.

Στη συνέχεια, παρατηρείται μεγάλος αριθμός keypoints εκεί όπου ο φράχτης και οι θάμνοι παρουσιάζουν πλούσια λεπτομέρεια (πλήθος φύλλων και κλαδιών), ενώ και η αλληλεπίδραση φωτεινότητας ανάμεσα στον σκούρο και τον φωτεινότερο τομέα ενισχύει τις εντοπισμένες μεταβολές. Η εικόνα περιλαμβάνει τόσο τεχνητές δομές (πεζοδρόμιο, τοίχοι κτιρίου) όσο και φυσικές (θάμνοι, δέντρα), προσφέροντας μια ποικιλία ακμών και μεταβολών.



Διαδικασία 6

Αρχικά, κάνουμε την παραδοχή ότι δεν θα χρησιμοποιήσουμε τον αλγόριθμο Sift που δίνεται. Έχει κάποιο θέμα με τον τρόπο που περνά τα keypoint στον επόμενο αλγόριθμο που βρίσκει τα outlier. Βάζουμε την αντίστοιχη function της matlab `detectSIFTFeatures`.

Οι εικόνες που επιλέξαμε για την άσκηση είναι οι παρακάτω:



Αυτές απεικονίζουν την ίδια ακριβώς σκηνή, απλά είναι τραβηγμένες από διαφορετική οπτική.

Προχωρώντας στον κώδικα, διαβάζουμε αυτές τις 2 εικόνες και με την εντολή `imrotate(img, 180)`, περιστρέφονται και οι δύο κατά 180 μοίρες, ώστε να εμφανιστούν στην κανονική τους όψη, αν έχουν αποθηκευτεί ανάποδα. Στη συνέχεια, πραγματοποιείται έλεγχος αν πρόκειται για έγχρωμες εικόνες (RGB). Εφόσον είναι τρικαναλες, γίνεται μετατροπή σε κλίμακα του γκρι (`rgb2gray`) για να μπορούν να εφαρμοστούν σωστά οι συναρτήσεις εντοπισμού και εξαγωγής SIFT χαρακτηριστικών.

Στην συνέχεια, η συνάρτηση `detectSIFTFeatures` χρησιμοποιείται σε κάθε εικόνα με τις παρακάτω παραμέτρους:

`ContrastThreshold = 0.04`: Καθορίζει το όριο πάνω από το οποίο θεωρούμε ότι ένα σημείο έχει επαρκή αντίθεση για να θεωρηθεί χαρακτηριστικό. Ένα χαμηλότερο `threshold` θα κρατούσε περισσότερα σημεία, αυξάνοντας όμως τον κίνδυνο θορυβωδών ή αδύναμων χαρακτηριστικών. Αντιθέτως, υψηλότερη τιμή θα φιλτράριζε πολλά υποψήφια σημεία, χάνοντας ενδεχομένως χρήσιμες πληροφορίες.

`EdgeThreshold = 5`: Αυτή η τιμή μειώνει τα `edge responses`, δηλαδή χαρακτηριστικά που εμφανίζονται σε πολύ έντονες γραμμές χωρίς πραγματικό

εσωτερικό ενδιαφέρον (π.χ. σε ακμές). Αν αυτό το όριο είναι πολύ χαμηλό, ο αλγόριθμος θα τείνει να απορρίπτει σημεία που βρίσκονται κοντά σε ακμές ενώ αν είναι πολύ υψηλό, μπορεί να κρατήσει πολλές ψευδοαντιστοιχίσεις από ισχυρές ακμές.

NumLayersInOctave = 5: Αναφέρεται στον αριθμό των επιπέδων (levels) εντός κάθε οκτάβας στο χώρο κλίμακας. Αυτή η τιμή ελέγχει πόσο πυκνά δειγματοληπτούμε τις διαφορετικές κλίμακες, επηρεάζοντας την ικανότητα του αλγόριθμου να ανιχνεύει χαρακτηριστικά αντικειμένων μεγάλου μεγέθους.

Sigma = sqrt(2): Προκαθορίζει την τυπική απόκλιση που χρησιμοποιείται σαν αφετηρία για τις Γκαουσιανές θολώσεις σε κάθε οκτάβα.

Παρακάτω, αφού εντοπιστούν τα keypoints (που αποθηκεύονται στις μεταβλητές siftPoints1 και siftPoints2), γίνεται η εξαγωγή των SIFT περιγραφών μέσω των εντολών:

```
[features1, validPts1] = extractFeatures(I1gray, siftPoints1, 'Method','SIFT');
```

```
[features2, validPts2] = extractFeatures(I2gray, siftPoints2, 'Method','SIFT');
```

Η επιλογή Method,'SIFT' διασφαλίζει ότι το matlab χρησιμοποιεί τον αλγόριθμο SIFT για τον υπολογισμό των 128-διάστατων descriptors. Οι μεταβλητές features1, features2 περιέχουν τα διανύσματα περιγραφής, ενώ validPts1, validPts2 είναι τα σημεία-κλειδιά που τελικά αποδόθηκαν επιτυχώς descriptors.

Επιπλέον, ο κώδικας καλεί τη συνάρτηση matchFeatures(features1, features2, ...), η οποία συγκρίνει όλα τα descriptors της πρώτης εικόνας με εκείνα της δεύτερης, επιστρέφοντας τις πιθανές αντιστοιχίσεις. Οι βασικές παράμετροι:

MaxRatio = 0.9: Ορίζει το όριο στον λόγο απόστασης (distance ratio) ανάμεσα στην καλύτερη και στη δεύτερη καλύτερη αντιστοίχιση για κάθε descriptor. Μια τιμή γύρω στο 0.8-0.9 είναι συνηθισμένη, ώστε να πετύχουμε λιγότερα ψευδή matches (αλλά με κίνδυνο να χάσουμε μερικά σωστά, αν είναι πολύ αυστηρό).

Unique = true: Απαιτεί από κάθε descriptor της πρώτης εικόνας να αντιστοιχίζεται το πολύ σε έναν descriptor της δεύτερης (αμοιβαία μοναδικότητα), αποφεύγοντας πολλαπλές αντανάκλασεις της ίδιας πληροφορίας.

Τέλος, εμφανίζονται οπτικά οι συζευγμένες τοποθεσίες (matchedPts1 και matchedPts2) στις δύο εικόνες, δίπλα-δίπλα.

Διαδικασία 7

Το ακρωνύμιο RANSAC προέρχεται από τις λέξεις "Random Sample Consensus" και περιγράφει μια επαναληπτική διαδικασία υπολογισμού όπου επιλέγονται τυχαία υποσύνολα δεδομένων, από τα οποία εκτιμάται ένα προκαθορισμένο μοντέλο, και στη συνέχεια ελέγχεται πόσα από τα υπόλοιπα δεδομένα ταιριάζουν με το μοντέλο αυτό (δηλαδή, πόσα σημεία θεωρούνται συμβατά ή inliers). Η βασική φιλοσοφία είναι ότι, ακόμα και αν στα δεδομένα υπάρχει μεγάλος αριθμός σφαλμάτων (outliers), υπάρχει αρκετή πιθανότητα κάποια τυχαία δείγματα να αποτελούνται αποκλειστικά ή σχεδόν αποκλειστικά από αληθή (inlier) δεδομένα, επιτρέποντας την εύρεση ενός ρεαλιστικού μοντέλου. Με επαναλαμβανόμενες τέτοιες δοκιμές (iterations), καταλήγουμε τελικά στην καλύτερη εκτίμηση του μοντέλου που εξηγεί τα περισσότερα δεδομένα.

Συνεχίζοντας, μπορούμε να δούμε τα βασικά βήματα του αλγορίθμου. Αρχικά, σε κάθε επανάληψη, επιλέγεται τυχαία ένα μικρό υποσύνολο σημείων (π.χ 2 ή 3 ζεύγη αντιστοιχισμένων σημείων). Από το επιλεγμένο υποσύνολο, εκτιμούμε (λύνουμε) το μαθηματικό μοντέλο που περιγράφει τη σχέση μεταξύ αυτών των σημείων (π.χ. ομοιότητα, μετάθεση). Για όλα τα υπόλοιπα σημεία, μετράμε τη συμβατότητά τους με το εκτιμώμενο μοντέλο (συνήθως μέσω μιας απόστασης σφάλματος, π.χ. πόσο πέφτει κοντά στην αναμενόμενη θέση). Επίσης, μετράμε πόσα σημεία εμπίπτουν σε ένα προκαθορισμένο όριο (threshold) απόστασης και θεωρούνται inliers. Αν ο αριθμός αυτός είναι ο μεγαλύτερος που έχουμε παρατηρήσει μέχρι στιγμής, ενημερώνουμε τον καλύτερο υπολογισμό μοντέλου. Η διαδικασία επαναλαμβάνεται για συγκεκριμένο αριθμό επαναλήψεων ή μέχρι να εξασφαλίσουμε πιθανότητα αρκετά υψηλή ότι έχουμε βρει το μοντέλο με τον μέγιστο αριθμό inliers.

Στο συγκεκριμένο κώδικα, η συνάρτηση `estimateGeometricTransform2D(...)` υλοποιεί εσωτερικά τον αλγόριθμο RANSAC. Συγκεκριμένα, δίνεται ένα σύνολο συντεταγμένων αντιστοιχισμένων σημείων (`matchedPts1.Location`, `matchedPts2.Location`). Μετα, ως μοντέλο ορίζεται ένα similarity transformation και θέτουμε τις παραμέτρους:

`MaxDistance = 5`: Ορίζει πόσο μακριά επιτρέπεται να πέφτει ένα σημείο από τη θεωρητική του θέση, για να θεωρηθεί συμβατό (inlier).

`Confidence = 99`: Σημαίνει ότι εκτελούμε αρκετούς κύκλους RANSAC ώστε να είμαστε κατά 99% σίγουροι πως έχουμε βρει το βέλτιστο ή σχεδόν βέλτιστο μοντέλο.

Η συνάρτηση, λοιπόν, εκτελεί τις πολλαπλές τυχαίες δειγματοληψίες και τους υπολογισμούς μοντέλου, μετράει πόσα σημεία θεωρούνται inliers σε κάθε μοντέλο και επιλέγει εκείνο που έχει τον μεγαλύτερο αριθμό. Τελικά, επιστρέφει τον εκτιμώμενο μετασχηματισμό (`tform`) καθώς και την μάσκα inliers (`inlierIdx`), δηλαδή τη λίστα με τα σημεία που θεωρούνται έγκυρα ταιρία.

Χωρίς Ransac:



Με Ransac:



Στην πρώτη εικόνα, διακρίνεται πληθώρα υποψήφιων αντιστοιχίσεων (κίτρινες γραμμές) που συνδέουν σημεία στις δύο λήψεις. Ωστόσο, ορισμένες γραμμές δεν έχουν γεωμετρική συνέπεια, αφού είναι είτε πολύ κεκλιμένες είτε συνδέουν τμήματα που οπτικά δεν συμπίπτουν στην πραγματική σκηνή. Αυτή η αρχική μεγάλη ποσότητα matches περιέχει τόσο ορθές όσο και λανθασμένες αντιστοιχίσεις, επειδή ο αλγόριθμος SIFT εστιάζει αποκλειστικά στην τοπική ομοιότητα των descriptors και δεν λαμβάνει υπόψη του την ολική διάταξη της σκηνής.

Στην δεύτερη εικόνα, ο αριθμός των γραμμών μειώνεται αισθητά, αλλά τα matches που επιβιώνουν είναι σχεδόν ευθυγραμμισμένα, κάτι που φανερώνει ότι απεικονίζουν την ίδια οριζόντια ζώνη. Αυτό το γεγονός υποδηλώνει ότι ο εκτιμώμενος μετασχηματισμός, τον οποίο υπολογίζει ο RANSAC, περιγράφει με

συνέπεια πώς η μία εικόνα προβάλλεται πάνω στην άλλη. Άρα, απορρίπτει όσα σημεία δεν υποστηρίζουν αυτό τον κοινό μετασχηματισμό, κρατώντας μονάχα τα inliers, που ανταποκρίνονται σε γνήσιες αντιστοιχίσεις.

Διαδικασία 8

Αρχικά, θα εξετάσουμε τις διαφορές του Sift και του Surf.

Ο αλγόριθμος SIFT εστιάζει στην προσέγγιση Laplacian of Gaussian (LoG) χρησιμοποιώντας τη Διαφορά Γκαουσιανών, ώστε να δημιουργήσει τον χώρο κλίμακας (scale space). Σε κάθε επίπεδο κλίμακας, ψάχνει τοπικά ακρότατα κάθε pixel σε μια 3D γειτονιά ($3 \times 3 \times 3$ σε τρεις διαδοχικές κλίμακες). Αυτή η προσέγγιση, παρότι πολύ σταθερή και ακριβής, προϋποθέτει αρκετές συνεχείς συνέλιξεις (convolutions) της αρχικής εικόνας με Γκαουσιανά φίλτρα.

Από την άλλη, ο SURF χρησιμοποιεί τη μέθοδο Fast-Hessian για την εύρεση ακροτάτων στον χώρο κλίμακας. Αντί για DoG, υπολογίζει, σε κάθε σημείο και κλίμακα, την ορίζουσα του Hessian ($\det(H)$) προσεγγίζοντας τους δεύτερους μερικούς παραγωγούς της Γκαουσιανής (LoG) με φίλτρα τύπου box (box filters). Έπειτα, αξιοποιεί τις integral images, ώστε ο υπολογισμός αυτών των φίλτρων να γίνεται σε σταθερό ή σχεδόν σταθερό χρόνο, ανεξάρτητα από το μέγεθος του φίλτρου. Έτσι, η προσέγγιση Fast-Hessian κάνει τον SURF πιο γρήγορο συγκριτικά με τον SIFT.

Αφού εντοπιστούν τα keypoints, ο SIFT καθορίζει την κυρίαρχη γωνία προσανατολισμού (orientation) εντός μιας περιοχής, υπολογίζοντας τα τοπικά ιστογράμματα κλίσης (gradient orientation histograms). Στη συνέχεια, για τον περιγραφέα, δημιουργεί ένα 4×4 πλέγμα υπό-περιοχών γύρω από κάθε keypoint, στο οποίο συγκεντρώνει τις κλίσεις (8 bins ανά υπό-περιοχή), με αποτέλεσμα έναν 128-διάστατο descriptor. Αυτή η λεπτομερής καταγραφή των κλίσεων καθιστά τον SIFT descriptor εξαιρετικά ανθεκτικό σε περιστροφές, αλλαγές κλίμακας και μέτριες μεταβολές φωτισμού.

Στον SURF, τοπικά Haar-wavelet φίλτρα (σε προσανατολισμένη μορφή) αντικαθιστούν τα αναλυτικά gradient histograms. Με εκμετάλλευση των integral images, ο υπολογισμός των wavelet αποκρίσεων (κλίσεις σε x και y) είναι πολύ γρήγορος. Ο κλασικός SURF descriptor είναι 64 διαστάσεων (ή 128 στην extended εκδοχή), ομαδοποιώντας τις αποκρίσεις αυτές σε λίγες υπό-περιοχές.

Ο SIFT έχει σημαντικό υπολογιστικό κόστος, καθώς απαιτεί πολλές Gaussian convolutions, διαδοχικές αναζητήσεις ακροτάτων και κατασκευή μεγάλων histogram bins. Για αυτόν τον λόγο, σε εφαρμογές real time, ο SIFT θεωρείται σχετικά αργός, ιδιαίτερα σε συσκευές με περιορισμένους πόρους (π.χ κινητά και embedded συστήματα).

Αντίθετα, ο SURF σχεδιάστηκε με προτεραιότητα την ταχύτητα, εκτελώντας τους περισσότερους υπολογισμούς (φίλτρα Hessian, wavelet αποκρίσεις κ.λπ.)

με integral images, που επιτρέπουν την παραγωγή αθροισμάτων pixel σε μεγάλες περιοχές με λίγες μόνο πράξεις.

Παρακάτω, μπορούμε να δούμε την μεγάλη διαφορά που έχουν στον χρόνο υπολογισμού:

detector	threshold	nb of points	comp. time (msec)
Fast-Hessian	600	1418	120
Hessian-Laplace	1000	1979	650
Harris-Laplace	2500	1664	1800
DoG	default	1520	400

	U-SURF	SURF	SURF-128	SIFT
time (ms):	255	354	391	1036

http://www.micc.unifi.it/delbimbo/wp-content/uploads/2011/03/slide_corso/A33%20SIFT-GLOH-SURF.pdf

<https://intapi.sciendo.com/pdf/10.2478/msr-2013-0021>

Τώρα, ας αναλύουμε τις διαφορές του Sift με τον Gloh. Ο προαναφερθέν είναι στην πραγματικότητα μία επέκταση του SIFT, προορισμένη να βελτιώσει τη διακριτική ικανότητα του descriptor. Ο SIFT βασίζεται στη Διαφορά Γκαουσιανών για να εντοπίσει ενδιαφέροντα σημεία σε πολλαπλές κλίμακες και συνθέτει έναν 128-διάστατο descriptor οργάνωνοντας τοπικές κλίσεις (gradient orientations) σε ένα 4×4 πλέγμα υπο-περιοχών. Ο GLOH διατηρεί την ίδια βασική μεθοδολογία ως προς την ανίχνευση ακροτάτων στον χώρο κλίμακας, αλλά διαφέρει στο πώς διατάσσει και κωδικοποιεί τις κλίσεις για να αυξήσει την πληροφορία και την ανθεκτικότητα σε πιο πολύπλοκες ή γεμάτες σκηνές.

Στον SIFT, ο υπολογισμός του descriptor γίνεται σε ένα καρτεσιανό πλέγμα 4×4 γύρω από κάθε σημείο-κλειδί, όπου σε κάθε υπό-περιοχή συγκεντρώνονται histogram bins των τοπικών κλίσεων. Αντίθετα, ο GLOH χρησιμοποιεί ένα log-polar σύστημα συντεταγμένων για την οργάνωση των κλίσεων γύρω από το keypoint. Συγκεκριμένα, χωρίζει τη γύρω περιοχή με 3 ακτινικές ζώνες (radial bins) και 8 γωνιακές περιοχές (angular bins), συνήθως συνδυάζοντάς τες με 16 bins προσανατολισμού. Με αυτόν τον τρόπο, καταγράφεται περισσότερη γεωμετρική πληροφορία για το πού εντοπίζονται οι κλίσεις σε σχέση με το κέντρο του σημείου, καθώς η κατανομή των gradient vectors αποτυπώνεται σε ένα πιο λεπτομερές πολικό πλέγμα.

Ο κλασικός SIFT descriptor έχει σταθερές 128 διαστάσεις: 16 υπό-περιοχές $\times$ 8 κατευθύνσεις ανά υπό-περιοχή. Στον GLOH, ο αρχικός descriptor μπορεί να φτάσει θεωρητικά έως και 272 διαστάσεις (για παράδειγμα 17 θέσεις $\times$ 16 bins προσανατολισμού = 272). Είναι σαφώς μεγαλύτερος, καθώς η log-polar δειγματοληψία μεγαλώνει το διάστημα θέσεων/γωνιών και αυξάνει τα bins. Στην πράξη, για να αποφευχθεί η αύξηση διαστάσεων και η υπερβολική υπολογιστική επιβάρυνση, ο GLOH εφαρμόζει PCA πάνω σε αυτές τις 272 διαστάσεις, συνήθως μειώνοντάς τις ξανά σε 128 ή κάποια άλλη μικρότερη διάσταση.

Εξαιτίας της λεπτομερέστερης περιγραφής (log-polar grid + περισσότερα bins), ο GLOH τείνει να έχει υψηλότερη διακριτική ικανότητα από τον SIFT, ιδίως σε σκηνές με πολλαπλές υφές, επαναλαμβανόμενα μοτίβα ή πολύπλοκα αντικείμενα. Στην πράξη, αυτό σημαίνει ότι μπορεί να πετύχει καλύτερη αναγνώριση αντικειμένων ή πιο αξιόπιστο matching χαρακτηριστικών. Ωστόσο, η αύξηση των διαστάσεων επιφέρει υψηλότερο υπολογιστικό κόστος.

https://medium.com/@vincentchung_72457/exploring-gradient-location-orientation-histogram-gloh-for-image-recognition-and-object-detection-3e3c231a5b01

Τέλος, συγκρίνουμε τον Gloh με τον Surf. Ο GLOH μπορεί να χρησιμοποιήσει τη λογική του LoG ή των παραγώγων της μέσω της Διαφοράς Γκαουσιανών, για να εντοπίσει τα ενδιαφέροντα σημεία. Στη συνέχεια, αυτά τα σημεία κλειδιά ενισχύονται από την εκτενέστερη ανάλυση κλίσεων που εφαρμόζει ο GLOH (όπως περιγράφεται στο descriptor). Αντιθέτως, ο SURF επιλέγει τη μέθοδο Fast-Hessian για τον εντοπισμό χαρακτηριστικών, όπου υπολογίζεται η ορίζουσα του Hessian μέσω box filters και integral images.

Ο GLOH συνδυάζει πληροφορία κλίσης (gradient orientation) με δεδομένα θέσης (location) σε ένα log-polar πλέγμα γύρω από το σημείο ενδιαφέροντος. Ειδικότερα, χωρίζει την περιοχή γύρω από το keypoint σε ακτινικούς και γωνιακούς τομείς και στη συνέχεια δημιουργεί bins προσανατολισμού. Έτσι, παράγεται ένας descriptor υψηλής διάστασης (έως και 272 bins), ο οποίος ο συχνά συμπιέζεται με PCA για να περιορίσει το μέγεθος. Στον SURF, αντιθέτως, ο descriptor βασίζεται σε απλουστευμένα Haar-wavelet φίλτρα υπολογισμένα με integral images. Η ιδέα είναι να συλλαμβάνεται ο προσανατολισμός (orientation) και η ένταση (magnitude) των κλίσεων γύρω από το keypoint, αλλά με έναν πιο compact τρόπο.

Η επιπλέον λεπτομέρεια του GLOH τού δίνει μεγαλύτερη ισχύ στη διάκριση λεπτομερειών. Αντιθέτως, ο SURF έχει σχεδιαστεί με έμφαση στην ταχύτητα. Σε συνθήκες όπου ο χρόνος επεξεργασίας είναι κρίσιμος, ο SURF αποδίδει καλύτερα διότι μπορεί να παρέχει αποτελέσματα πολύ γρήγορα. Ο GLOH, αντίθετα, είναι πιο υπολογιστικά βαρύς και μεγαλύτερος σε διάσταση.

Διαδικασία 9

Sift:

https://www.researchgate.net/publication/252048719_Analyzing_and_exploring_feature_detectors_in_images#pf6

Σε αυτό το paper ο SIFT εντοπίζει χαρακτηριστικά σημεία σε πολλαπλές κλίμακες, εκτιμά τον προσανατολισμό τους και στη συνέχεια εξάγει έναν περιγραφέα (descriptor) 128 διαστάσεων για κάθε σημείο. Στόχος είναι να εξηγηθεί πώς προκύπτει η πολυπλοκότητα $O(mn+k)$, όπου $m \times n$ είναι το μέγεθος της εικόνας και k ο αριθμός των τελικών ανιχνευμένων σημείων.

Στο πρώτο στάδιο, ο αλγόριθμος κατασκευάζει μια πυραμίδα πολλαπλών κλιμάκων, εφαρμόζοντας διαδοχικές συνελίξεις με Γκαουσιανά φίλτρα σε διαφορετικά επίπεδα θορύβου. Παρακάτω, υπολογίζεται η Difference of Gaussians, προκειμένου να βρεθούν τα ακραία σημεία. Σε κάθε επίπεδο ανάλυσης (octave), η εικόνα είτε φιλτράρεται με μεγαλύτερο Γκαουσιανό πυρήνα είτε μειώνεται σε διαστάσεις στο μισό. Με αυτόν τον τρόπο, η συνολική επεξεργασία δεν ξεπερνά το $O(mn)$, καθώς τα επίπεδα πυραμίδας προστίθενται μεν, αλλά το μέγεθος της εικόνας σε κάθε επόμενο επίπεδο μειώνεται εκθετικά.

Στη συνέχεια, τα σημεία που αποτελούν τοπικά ακρότατα στο DoG ανιχνεύονται κάνοντας συγκρίσεις με τα 8 γειτονικά pixels της ίδιας κλίμακας και τα 9 από την αμέσως προηγούμενη και επόμενη κλίμακα. Η διαδικασία αυτή επαναλαμβάνεται σε κάθε οκτάβα, με τον αριθμό Pixel να μειώνεται σε κάθε μείωση κλίμακας. Η θεωρητική ανάλυση δείχνει ότι και αυτό το υπό-στάδιο διατηρεί πολυπλοκότητα επιπέδου $O(mn)$.

Αφού εντοπιστούν τα ακρότατα σημεία, ακολουθεί ένα βήμα ακριβούς εντοπισμού. Σε αυτό, αφαιρούνται σημεία που δεν έχουν επαρκή αντίθεση. Αυτό το στάδιο εξαρτάται πλέον από τον αριθμό των υποψηφίων σημείων. Έτσι, αν τα αρχικά σημεία που πέρασαν το DoG τεστ είναι k , το κόστος για τον ακριβή εντοπισμό παραμένει $O(k)$, κάτι που δεν αλλάζει τη γενική συμπεριφορά για μεγάλες εικόνες, μιας και συνήθως $k \ll mn$.

Στο τέλος καταλήγουμε στο πόρισμα ότι η ασυμπτωτική πολυπλοκότητα του SIFT μπορεί να εκφραστεί από τον όρο $O(mn+k)$.

Surf: Έχει το μικρότερο υπολογιστικό κόστος από τους άλλους 2 αλγορίθμους όπως έχουμε εξηγήσει παραπάνω.

Gloh: Έχει το μεγαλύτερο υπολογιστικό κόστος.