

Άσκηση 5

Θέματα Όρασης Υπολογιστών

Περιεχόμενα

Μείωση Διαστατικότητας των Δεδομένων	3
Απόδειξη 1.....	3
Απόδειξη 2	4
Απόδειξη 3	5
Απόδειξη 4	5
Διατύπωση 1.....	6
Απόδειξη 5	6
Απόδειξη 6	6
Διαδικασία 1.....	7
α).....	7
β).....	7
γ).....	8
δ).....	8
ε)	9
Διαδικασία 2	10
α).....	10
β).....	10
PCA Βασισμένη σε Πυρήνες.....	11
Διαδικασία 2	11
α).....	11
β).....	12
γ).....	12
δ).....	13
ε)	13
Autoencoders.....	14
Διαδικασία 1.....	14
Διαδικασία 2	14
Διαδικασία 3	15
α).....	15

β).....	15
Διαδικασία 4.....	15
Διαδικασία 5.....	16
Πιθανοτική PCA.....	17
Απόδειξη 1.....	17
Απόδειξη 2.....	18
Kullback-Leibler Divergence	18
Απόδειξη 1.....	18
Απόδειξη 2.....	18
Variational Autoencoders	19
Διαδικασία 1.....	19
α).....	19
β).....	20

Όλος ο κώδικας έχει γίνει στο google collab και μπορεί να βρεθεί εδώ:

<https://github.com/GrigorisTzortzakis/Computer-Vision/tree/main/Exercise%205>

Μείωση Διαστατικότητας των Δεδομένων

Απόδειξη 1

Μπορούμε να καταλάβουμε γιατί η κατεύθυνση που μεγιστοποιεί τη διασπορά των προβολών των δεδομένων σε έναν άξονα (δηλαδή για $L=1$) ισοδυναμεί με τη λύση του προβλήματος βελτιστοποίησης $\max_{v_1} v_1^T S v_1$ με περιορισμό $\|v_1\|_2=1$ μέσα από τα παρακάτω βήματα:

1. Σύνδεση διασποράς και γραμμικής προβολής

Ο στόχος της PCA (για μία διάσταση) είναι να βρούμε μια γραμμική προβολή των σημείων (δηλαδή ένα μοναδιαίο διάνυσμα v_1), ώστε όταν προβάλλουμε τα διανύσματα x_m πάνω σε αυτόν τον άξονα, η διασπορά των προβαλλόμενων τιμών να είναι όσο το δυνατόν μεγαλύτερη. Η προβολή ενός σημείου x_m πάνω σε έναν άξονα καθορισμένο από το διάνυσμα v_1 δίνεται από το γινόμενο $v_1^T x_m$. Εάν θέλουμε να συνοψίσουμε τη διασπορά για όλα τα δείγματα, αρκεί να μελετήσουμε τη συνάρτηση $v_1^T S v_1$, όπου $S = X X^T$. Με απλά λόγια, το μέγεθος $v_1^T S v_1$, μετράει πόσο μεγάλη είναι η μεταβλητότητα των σημείων όταν τα δούμε κατά την κατεύθυνση v_1 .

2. Ο περιορισμός στην κανονικοποίηση

Ο περιορισμός $\|v_1\|_2=1$ σημαίνει ότι απαιτούμε το διάνυσμα v_1 να έχει μήκος ίσο με τη μονάδα. Αυτό είναι απαραίτητο, αλλιώς, αν μπορούσαμε να αυξήσουμε το μήκος του v_1 αυθαίρετα, η τιμή $v_1^T S v_1$ θα γινόταν απεριόριστα μεγάλη και το πρόβλημα δεν θα λυνόταν. Με άλλα λόγια, θέτουμε μια κλίμακα στον χώρο των λύσεων, δηλαδή συγκρίνουμε όλες τις κατευθύνσεις ως μοναδιαίες διευθύνσεις.

3. Προσέγγιση μέσω Lagrange

Για να επιλυθεί το πρόβλημα καταφεύγουμε στην τεχνική των πολλαπλασιαστών Lagrange. Ορίζουμε τη συνάρτηση $L(v_1, \lambda) = v_1^T S v_1 - \lambda * (\|v_1\|_2^2 - 1)$ όπου το λ είναι ο πολλαπλασιαστής Lagrange που επιβάλλει τον περιορισμό. Για να βρούμε τα ακρότατα της $L(v_1, \lambda)$ θέτουμε τις παραγώγους ως προς v_1 και λ ίσες με το μηδέν. Η συνθήκη $\frac{\partial L}{\partial v_1} = 0$ οδηγεί σε $2Sv_1 - 2\lambda v_1 = 0$. Αυτό σημαίνει ότι το διάνυσμα v_1 είναι ιδιοδιάνυσμα του S και το λ η αντίστοιχη ιδιοτιμή.

4. Σύνδεση με την κυρία ιδιοτιμή

Εφόσον το λ εμφανίζεται ως παράγοντας μεγιστοποίησης, τότε είναι η μέγιστη ιδιοτιμή του S . Σε εκείνη, το αντίστοιχο ιδιοδιάνυσμα v_1 μας δίνει ακριβώς την κατεύθυνση που επιτυγχάνει τη μέγιστη δυνατή διασπορά. Άρα η λύση του προβλήματος είναι να βρούμε την κυρία (δηλαδή μεγαλύτερη) ιδιοτιμή του S

και να πάρουμε ως v_1 το ιδιοδιάνυσμα που αντιστοιχεί σε αυτήν την ιδιοτιμή, κανονικοποιημένο ώστε να έχει μήκος 1.

5. Σχέση με την πρώτη κύρια συνιστώσα

Η κατεύθυνση v_1 που μεγιστοποιεί τη διασπορά είναι η πρώτη κύρια συνιστώσα (principal component). Αυτό θεμελιώνει τον πρώτο ορισμό που δώσαμε για την PCA, ο οποίος είναι η αναζήτηση ορθοκανονικών διανυσμάτων που μεγιστοποιούν διαδοχικά τη διασπορά των προβολών των δεδομένων. Για $L=1$, αυτό μεταφράζεται στην αναζήτηση της μίας διάστασης που εξηγεί τη μεγαλύτερη μεταβλητότητα μέσα στο σύνολο δεδομένων. Συνεπώς, η απόδειξη ότι η κατεύθυνση της πρώτης κύριας συνιστώσας ισοδυναμεί με τη λύση του προβλήματος $\max_{v_1} v_1^T S v_1$ υπό τον περιορισμό $\|v_1\|_2 = 1$ προκύπτει άμεσα από το γεγονός ότι το ζητούμενο διάνυσμα είναι ιδιοδιάνυσμα της συνδιασποράς με τη μέγιστη ιδιοτιμή και η κανονικοποίησή του εξασφαλίζει την ικανοποίηση του περιορισμού μήκους.

Αν δεν μας δίνεται το L , η κλασική προσέγγιση είναι να εξετάσουμε το άθροισμα των ιδιοτιμών (ή ισοδύναμα το ποσοστό της σωρευτικής διασποράς) που εξηγούν οι πρώτες L κύριες συνιστώσες. Συγκεκριμένα, κατατάσσουμε τις ιδιοτιμές του πίνακα συνδιασποράς σε φθίνουσα σειρά και αθροίζουμε τις μεγαλύτερες μέχρι να φτάσουμε σε κάποιο επιθυμητό ποσοστό (π.χ. 90%, 95%) της συνολικής διακύμανσης. Εφόσον αυτό το επιθυμητό ποσοστό ξεπεραστεί για πρώτη φορά στην L -οστή ιδιοτιμή, θέτουμε L ίσο με εκείνο το σημείο. Με τον τρόπο αυτό, διατηρούμε εκείνο το υποδιάστημα που εξηγεί το μεγαλύτερο μέρος της μεταβλητότητας των δεδομένων, παραλείποντας διαστάσεις που περιέχουν ελάχιστη πληροφορία.

Αν τα δεδομένα δεν είναι μηδενικής μέσης τιμής, μπορούμε πάντα να τα κεντράρουμε απομακρύνοντας από το κάθε διάνυσμα x_m τον μέσο όρο $\bar{x}$ του δείγματος. Πιο συγκεκριμένα, υπολογίζουμε $\bar{x} = \frac{1}{M} \sum_{m=1}^M x_m$ και ορίζουμε τα κεντραρισμένα δείγματα ως $\tilde{x}_m = x_m - \bar{x}$

Απόδειξη 2

Θέλουμε να βρούμε τη μοναδιαία κατεύθυνση v_1 που μεγιστοποιεί την ποσότητα $v_1^T S v_1$. Το S είναι ένα πραγματικό, συμμετρικό και θετικό μητρώο (θεωρούμε ότι προέρχεται από συνδιασπορές). Αυτή η ποσότητα εκφράζει τη διασπορά των δεδομένων όταν προβάλλονται στην κατεύθυνση v_1 .

1. Επίλυση με τη μέθοδο των Lagrange πολλαπλασιαστών

Ορίζουμε τη συνάρτηση $L(v_1, \lambda) = v_1^T S v_1 - \lambda (\|v_1\|_2^2 - 1)$ όπου λ είναι ο πολλαπλασιαστής Lagrange. Για να βρούμε τις τιμές των v_1 και λ που μεγιστοποιούν τη L , θέτουμε τις παραγώγους της ως προς v_1 και λ ίσες με το μηδέν. Είναι δηλαδή:

$\frac{\partial L}{\partial v_1} = 2Sv_1 - 2\lambda v_1 = 0 \Rightarrow Sv_1 = \lambda v_1$ και η σχέση $Sv_1 = \lambda v_1$ δείχνει ότι v_1 είναι ιδιοδιάνυσμα του S , με ιδιοτιμή λ . Συνεχίζοντας, είναι $\frac{\partial L}{\partial \lambda} = -(\|v_1\|_2^2 - 1) = 0 \Rightarrow \|v_1\|_2^2 = 1$ και έτσι επαληθεύουμε ότι ισχύει ο αρχικός μας περιορισμός κανονικοποίησης.

2. Επιλογή της μέγιστης ιδιοτιμής

Αφού v_1 πρέπει να είναι ιδιοδιάνυσμα, η τιμή της συνάρτησης $v_1^T S v_1$ ταυτίζεται με την ιδιοτιμή λ που αντιστοιχεί σε αυτό το ιδιοδιάνυσμα. Για να επιτύχουμε τη μέγιστη δυνατή τιμή πρέπει να επιλέξουμε εκείνο το ιδιοδιάνυσμα του S που αντιστοιχεί στη μεγαλύτερη ιδιοτιμή του. Επομένως, αν λ_1 είναι η μέγιστη ιδιοτιμή του S και v_1 το αντίστοιχο ιδιοδιάνυσμα, τότε $v_1^* = \operatorname{argmax}_{\|v_1\|^2=1} v_1^T S v_1$ και $(v_1^*)^T S v_1^* = \lambda_1$.

Συμπερασματικά, η λύση του προβλήματος βελτιστοποίησης είναι το κανονικοποιημένο ιδιοδιάνυσμα του S που αντιστοιχεί στη μέγιστη ιδιοτιμή του.

Απόδειξη 3

Για την περίπτωση $L=2$, η βασική ιδέα παραμένει ίδια με το $L=1$, δηλαδή αναζητούμε τον επόμενο κύριο άξονα που μεγιστοποιεί τη διασπορά, αλλά τώρα εισάγουμε πρόσθετο περιορισμό σε σχέση με τον πρώτο άξονα v_1^* . Συγκεκριμένα, ο στόχος μας είναι και πάλι να βρούμε ένα διάνυσμα v_2 που να μεγιστοποιεί το $v_2^T S v_2$ και πρέπει το v_2 να είναι διαφορετική κατεύθυνση από το v_1^* και κανονικά να είναι ορθογώνιο προς αυτό. Ουσιαστικά, η μόνη διαφορά από την περίπτωση $L=1$ είναι ότι τώρα ο δεύτερος κύριος άξονας πρέπει να είναι διαφορετικός (ορθογώνιος) από τον πρώτο, ενώ με τον περιορισμό $(v_1^*, v_2) \geq 0$ επιλέγουμε τη θετική φορά για το v_2 .

Απόδειξη 4

Σε αυτήν την απόδειξη, το μόνο καινούργιο στοιχείο που απαιτείται σε σχέση με την περίπτωση $L=1$ είναι ο πρόσθετος περιορισμός ως προς τον ήδη υπολογισμένο πρώτο κύριο άξονα v_1^* . Στη συνέχεια, όταν γενικεύουμε σε αυθαίρετο L , η ίδια λογική επαναλαμβάνεται βήμα-βήμα με την αρχή της επαγωγής. Όλα τα υπόλοιπα βήματα είναι τα ίδια. Αναλυτικότερα, για να περάσουμε από τον ήδη γνωστό πρώτο άξονα v_1^* (με ιδιοτιμή λ_1) στον δεύτερο άξονα v_2^* , επιβάλλουμε μόνο ότι το νέο διάνυσμα v_2 παραμένει μοναδιαίο και συνεπές με τον πρώτο, θέτοντας ως πρόσθετη συνθήκη το $(v_1^*, v_2) \geq 0$. Η μέθοδος βελτιστοποίησης δείχνει και εδώ ότι v_2 πρέπει να είναι ιδιοδιάνυσμα του S . Επιλέγοντας τη δεύτερη μεγαλύτερη ιδιοτιμή λ_2 , επιτυγχάνουμε την

επόμενη μέγιστη διασπορά, οπότε ο δεύτερος άξονας προκύπτει ως το ιδιοδιάνυσμα v_2^* που αντιστοιχεί σε αυτήν.

Διατύπωση 1

Έστω ότι έχουν ήδη υπολογιστεί οι πρώτοι $k-1$ κύριοι άξονες $\{v_1^*, \dots, v_{k-1}^*\}$

που αντιστοιχούν στις $k-1$ μεγαλύτερες ιδιοτιμές $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_{k-1}$. Για τον k -οστό άξονα επιβάλλουμε τη βελτιστοποίηση $\max_{v_k} v_k^T S v_k$ με μοναδική νέα προσαρμογή το ότι κάθε νέος άξονας v_k πρέπει να ταιριάζει σε πρόσημο με όλους τους ήδη γνωστούς. Όπως και πριν, η τυπική επίλυση οδηγεί στο συμπέρασμα ότι το v_k είναι ιδιοδιάνυσμα του S , ενώ για να είναι η k -οστή διάσταση μέγιστης διασποράς, η ιδιοτιμή που επιλέγουμε είναι η λ_k .

Απόδειξη 5

Η απόδειξη βασίζεται στο λεγόμενο θεώρημα Eckart-Young-Mirsky για την καλύτερη προσεγγιστική παραγοντοποίηση χαμηλής τάξης (rank) σε Frobenius νόρμα, καθώς και στη διαγώνια μορφή του S μέσω της SVD του X . Το ουσιαστικό βήμα είναι να δούμε ότι η βέλτιστη λύση προκύπτει από την αφαίρεση όλων των μικρότερων ιδιάζουσων τιμών και τη διατήρηση μόνο των L μεγαλύτερων. Πιο συγκεκριμένα, ξεκινάμε από το γεγονός ότι S μπορεί να γραφεί ως $V \Sigma_0 V^T$, όπου όπου Σ_0 είναι διαγώνιο μητρώο που περιέχει (στη διαγώνιό του) τις ιδιάζουσες τιμές του X . Για την αναζήτηση ενός προσεγγιστικού πίνακα A τάξης L που ελαχιστοποιεί τη Frobenius νόρμα $\|S - A\|_F^2$, το θεωρητικό αποτέλεσμα της βέλτιστης rank- L προσέγγισης λέει ότι αρκεί να μηδενιστούν (στη Σ_0) όλες οι ιδιάζουσες τιμές εκτός από τις L μεγαλύτερες. Πρακτικά, αυτό ισοδυναμεί με το να περιορίσουμε τον πίνακα V στις πρώτες L στήλες (V_L) και να περιορίσουμε τη Σ_0 στις αντίστοιχες πρώτες L μεγαλύτερες τιμές (Σ_L), λαμβάνοντας τελικά τον πίνακα $A^* = V_L \Sigma_L V_L^T$.

Απόδειξη 6


Για να αποδείξουμε ότι η Frobenius στάθμη ενός πίνακα C ισούται με την ℓ_2 στάθμη του διανύσματος που προκύπτει από τις γραμμές (ή από τις στήλες) του, ξεκινάμε από τον ορισμό της Frobenius στάθμης. Συγκεκριμένα, για έναν πίνακα $C \in \mathbb{R}^{m \times n}$ η Frobenius στάθμη ορίζεται ως το τετραγωνικό άθροισμα όλων των στοιχείων του, δηλαδή $\|C\|_F^2 = \sum_{i=1}^m \sum_{j=1}^n |c_{i,j}|^2$. Στη συνέχεια, θεωρούμε το διάνυσμα που προκύπτει αν στοιχίσουμε διαδοχικά τις γραμμές (ή εναλλακτικά τις στήλες) του πίνακα C . Για παράδειγμα, ορίζουμε ένα διάνυσμα c στο $\mathbb{R}^{mn}$ στοιχίζοντας τις γραμμές του C ως εξής: $c = (c_{1,1}, c_{1,2}, \dots, c_{2,1})^T$. Η ℓ_2 στάθμη του c ορίζεται ως $\|c\|_2^2 = \sum_{k=1}^{mn} |c_k|^2$. Παρατηρούμε όμως ότι τα c_k δεν

είναι παρά όλα τα στοιχεία $c_{i,j}$ του πίνακα C, καθένα τους ακριβώς μία φορά άρα τα 2 αθροίσματα ταυτίζονται.

Διαδικασία 1

α)

Αρχικά, το dataset αποτελείται από τα ψηφία 0-9 που είναι το καθένα γραμμένο με διαφορετικό τρόπο. Στη συνέχεια, εφαρμόζουμε τον μετασχηματισμό `ToTensor()`, μετατρέποντας κάθε εικόνα σε ένα PyTorch Tensor 3 διαστάσεων [1,28,28]. Έτσι, κάθε pixel μεταφράζεται σε μια αριθμητική τιμή στο εύρος [0,1]. Αφού φορτώθηκε το πλήρες train set του MNIST, επιλέξαμε δύο κατηγορίες (ψηφία), το 3 και το 7. Για κάθε ζεύγος (εικόνα, ετικέτα) στο dataset, ελέγξαμε αν η ετικέτα ταυτίζεται με το 3 ή το 7 και στη συνέχεια αποθηκεύσαμε το αντίστοιχο Tensor σε ξεχωριστές λίστες. Με αυτό τον τρόπο, απομονώσαμε μόνο τα δείγματα που μας ενδιέφεραν, δημιουργώντας δύο κλάδους δεδομένων, έναν για το ψηφίο 3 και έναν για το ψηφίο 7. Οι λίστες που προέκυψαν ενώθηκαν (stack) σε ενιαία Tensors, όπου κάθε τετραδιάστατο Tensor είχε σχήμα [N,1,28,28], με N να είναι ο αριθμός των δειγμάτων της συγκεκριμένης κατηγορίας. Στη συνέχεια, κληθήκαμε να υπολογίσουμε τον μέσο όρο κάθε pixel διασχίζοντας τον πρώτο άξονα (εκείνον του N). Η πράξη αυτή μας έδωσε για κάθε ψηφίο ένα Tensor σχήματος [1,28,28], το οποίο αναπαριστά την μέση εικόνα. Με άλλα λόγια, σε κάθε pixel προκύπτει ο μέσος όρος των αντίστοιχων τιμών για όλα τα δείγματα του ψηφίου. Τέλος, μετά την ολοκλήρωση των υπολογισμών, αναδιατάξαμε κάθε μέσο Tensor σε δισδιάστατο σχήμα [28×28] και το προβάλαμε με τη `matplotlib`. Από τα αποτελέσματα βλέπουμε ότι οι μέσες εικόνες για το 3 και το 7 ήταν θολές αλλά ευδιάκριτα κοντά στις πραγματικές γραμμές και καμπύλες που χαρακτηρίζουν τα αντίστοιχα ψηφία.



β)


Για να υπολογίσουμε το μητρώο συνδιασπορών πρώτα επιλέγουμε τα αντίστοιχα ψηφία και φιλτράρουμε το dataset ώστε να κρατήσουμε μόνο όσα δείγματα ανήκουν σε αυτά. Έπειτα, κεντράρουμε τα δεδομένα αφαιρώντας τον μέσο όρο κάθε χαρακτηριστικού (δηλαδή τον μέσο όρο τιμών ανά pixel), ώστε να απομακρύνουμε τυχόν μετατοπίσεις. Το μητρώο συνδιασπορών προκύπτει

από τον τύπο $S = \frac{1}{N-1} X^T X$, όπου X είναι ο πίνακας των κεντραρισμένων δειγμάτων και N ο αριθμός τους, με διαστάσεις $[784 \times 784]$ στην περίπτωση που διατηρούνται όλα τα pixels ως χαρακτηριστικά. Κάθε στοιχείο $S_{i,j}$ αντανακλά τη γραμμική συσχέτιση μεταξύ του i και του j πίξελ, ενώ τα διαγώνια στοιχεία S_{ii} αντιπροσωπεύουν τη διακύμανση στο i -οστό πίξελ. Εάν κάποια στοιχεία της διαγωνίου προκύψουν μηδενικά, αυτό σημαίνει ότι οι τιμές του αντίστοιχου πίξελ δεν διαφοροποιούνται στα δείγματα των επιλεγμένων ψηφίων (ή ότι ο αριθμός δειγμάτων είναι ανεπαρκής).

```
Σχήμα του μητρώου συνδιασπορών: torch.Size([784, 784])
Ενδεικτικά, μερικές τιμές από την κύρια διαγώνιο:
tensor([0., 0., 0., 0., 0., 0., 0., 0., 0., 0.])
```

γ)


Η ανάλυση των οκτώ πρώτων κύριων συνιστωσών στα δύο ψηφία βασίζεται στη μετατροπή κάθε εικόνας σε διάνυσμα 784 διαστάσεων, το κεντράρισμα των δεδομένων (αφαίρεση του μέσου όρου) και τη διάσπασή τους σε διαστάσεις μέγιστης διασποράς. Κάθε συνιστώσα εμφανίζεται ως ένα πρότυπο που δείχνει πού εντοπίζονται οι πιο σημαντικές διαφοροποιήσεις των δειγμάτων, δηλαδή οι φωτεινές και σκοτεινές περιοχές αποκαλύπτουν τα σημεία όπου τα pixels μεταβάλλονται περισσότερο μεταξύ των δειγμάτων. Στην περίπτωση μας, η πρώτη συνιστώσα καλύπτει περίπου το 17.87% της συνολικής διασποράς, υποδηλώνοντας ότι μια μόνο κατεύθυνση στον χώρο των pixels εξηγεί σχεδόν το 1/6 της συνολικής μεταβλητότητας, ενώ οι επόμενες συνιστώσες αποτυπώνουν προοδευτικά μικρότερα ποσοστά. Ορισμένες συνιστώσες εστιάζουν κυρίως στις οριζόντιες γραμμές και μερικές άλλες αναδεικνύουν μικρές διαφορές στο κορμό των ψηφίων. Τέλος, το αποτέλεσμα δείχνει ότι το μεγαλύτερο μέρος της πληροφορίας διαχωρισμού ανάμεσα στα δύο ψηφία κωδικοποιείται στις πρώτες συνιστώσες, ενώ οι επόμενες υψηλότερης τάξης συνιστώσες αποτυπώνουν λεπτομερέστερες και λιγότερο εμφανείς πτυχές.



δ)


Η βασική ιδέα για την ανακατασκευή μιας εικόνας (ή γενικότερα ενός δείγματος) με PCA ξεκινά από το ότι, αφού κεντράρουμε όλα τα δείγματα αφαιρώντας τον μέσο όρο τους, υπολογίζουμε μια ορθοκανονική βάση κυρίων

συνιστωσών, ταξινομημένη από τη μεγαλύτερη ως τη μικρότερη ιδιοτιμή. Όταν αποφασίζουμε να κρατήσουμε μόνο τις πρώτες L συνιστώσες, προβάλλουμε κάθε δείγμα σε αυτές τις L διαστάσεις (υπολογίζοντας τα εσωτερικά γινόμενα με καθεμία) και στη συνέχεια ανασυνθέτουμε το δείγμα προσθέτοντας τον μέσο όρο και λαμβάνοντας το γραμμικό άθροισμα των L επιλεγμένων συνιστωσών, κλιμακωμένων με τους αντίστοιχους συντελεστές προβολής. Πρακτικά, για πολύ μικρό L έχουμε μια εξαιρετικά φτωχή αναπαράσταση, καθώς αξιοποιείται μόνο η σημαντικότερη, αλλά όχι η πλήρης διασπορά του σήματος. Δηλαδή, καθώς αυξάνουμε το L , ενσωματώνουμε προοδευτικά περισσότερες διαστάσεις πληροφορίας και βελτιώνεται η ακρίβεια της ανακατασκευής, με το όριο να αποτελεί η περίπτωση όπου παίρνουμε όλες τις συνιστώσες, οπότε το δείγμα αναπαράγεται ουσιαστικά χωρίς απώλεια.



ε)

Αρχικά, αθροίζουμε και διαιρούμε για να βρούμε τον μέσο όρο, ώστε στη συνέχεια να κεντράρουμε όλα τα δείγματα γύρω από το μηδέν. Συνεχίζοντας, εφαρμόζουμε PCA στο κεντραρισμένο σύνολο δειγμάτων και βρίσκουμε διαδοχικά τις L κατευθύνσεις μέγιστης διασποράς στον χώρο των χαρακτηριστικών. Παρακάτω, αφού μετασχηματίσουμε κάθε δείγμα στις L κύριες συνιστώσες, μπορούμε να το ανακτήσουμε πίσω στο πλήρες διάστημα μέσω της αντίστροφης προβολής. Ουσιαστικά, αυτό ισοδυναμεί με το να σχηματίσουμε ένα γραμμικό άθροισμα των L κύριων συνιστωσών, σταθμισμένο με τους συντελεστές που προέκυψαν από την προβολή, και κατόπιν να προσθέσουμε ξανά τον μέσο όρο που είχαμε αφαιρέσει στην αρχή. Όσο μεγαλύτερο είναι το L , τόσο περισσότερη πληροφορία διατήρησαν τα δείγματα, και κατά κανόνα τόσο πιο πιστή γίνεται η ανακατασκευή. Για κάθε δείγμα, ορίζουμε το σφάλμα ανακατασκευής ως τη μέση τετραγωνική διαφορά μεταξύ του αρχικού διανύσματος και της ανακατασκευασμένης εκδοχής του. Έτσι, για μικρά L , η απώλεια πληροφορίας είναι συνήθως αισθητή και το σφάλμα είναι υψηλό. Καθώς αυξάνουμε τις συνιστώσες, το σφάλμα τείνει να μειώνεται.



Διαδικασία 2


α)

Ο κώδικας μετατρέπει το σύνολο εκπαίδευσης σε έναν πίνακα $[N, 784]$, όπου N είναι ο αριθμός των δειγμάτων. Έπειτα, κεντράρει τα δεδομένα αφαιρώντας τον μέσο όρο κάθε χαρακτηριστικού (pixel). Στη συνέχεια, ορίζει το μοντέλο $n_components=128$ και το εκπαιδεύει (`pca.fit`), ώστε να βρει τις 128 κατευθύνσεις μέγιστης διασποράς. Το μητρώο VL προκύπτει από το `pca.components_.T` και για την ανακατασκευή, εφαρμόζουμε τον αντίστροφο μετασχηματισμό (`pca.inverse_transform`) ώστε να φέρουμε ξανά κάθε δείγμα πίσω στο διάστημα των 784 διαστάσεων και προσθέτουμε τον μέσο όρο (`mean_vec`) για να επαναφέρουμε τα δεδομένα στη φυσική κλίμακά τους.

```
Μέγεθος συνόλου εκπαίδευσης (X): (60000, 784)
Σχήμα του πίνακα V_L: (784, 128)
Σχήμα των ανακατασκευασμένων δεδομένων: (60000, 784)
Μέσο Σφάλμα Ανακατασκευής (MSE) για L=128: 0.0043
```

β)

Εξετάζουμε πόσο καλά λειτουργεί η pca σε δείγματα που δεν έχει δει κατά την εκπαίδευση της.



Μπορούμε να δούμε ότι ακόμα και όταν χρησιμοποιούμε μόλις 128 από τις 784 διαστάσεις, οι εικόνες είναι αναγνωρίσιμες αν και παρουσιάζουν σχετικά μεγάλη απώλεια πληροφορίας.


PCA Βασισμένη σε Πυρήνες

Στην κλασική PCA, εργαζόμαστε απευθείας στον χώρο R^N και προϋποθέτουμε ότι τα δεδομένα είναι κεντραρισμένα, υπολογίζοντας τον πίνακα συνδιασποράς $S = XX^T$. Στην kernel Pca, πρώτα ορίζουμε έναν μη γραμμικό μετασχηματισμό $k(x): R^N \rightarrow R^D$ και χρησιμοποιούμε μια συνάρτηση πυρήνα ώστε να αποφύγουμε την ρητή απεικόνιση σε πολύ (ή άπειρα) μεγάλες διαστάσεις. Ο πίνακας πυρήνα $K [M \times M]$ κωδικοποιεί τα εσωτερικά γινόμενα $(k(x_i), k(x_j))$, αντί να δουλεύουμε με διανύσματα $zm = k(x_m)[D]$. Για να εφαρμόσουμε PCA, πρέπει να κεντράρουμε τον πίνακα πυρήνα (αφαιρώντας την μετατόπιση). Αν η μέση τιμή δεν είναι μηδενική στον χώρο χαρακτηριστικών, ο πίνακας K διορθώνεται κατάλληλα μέσω γνωστών τύπων (centering), ώστε να εξασφαλίσουμε ότι $\sum_m k(x_m) = 0$. Έτσι, η κύρια διαφορά από την κλασική προσέγγιση είναι ότι δεν χρησιμοποιούμε απευθείας τους πίνακες στο R^N αλλά τα εσωτερικά γινόμενα στον χώρο R_D .

Διαδικασία 1

α)

Η κύρια αλλαγή είναι ότι στην pca το μέσο ψηφίο ορίζεται ως ο pixel μέσος όρος όλων των δειγμάτων στο αρχικό διάστημα 784 διαστάσεων, με αποτέλεσμα μια νέα εικόνα 28x28. Όταν όμως ορίζουμε έναν μη γραμμικό μετασχηματισμό, η έξοδος είναι μόνο ένας βαθμωτός για κάθε εικόνα. Επομένως, το μέσο ψηφίο στον χώρο του k παύει να είναι μια εικόνα και περιορίζεται σε μια αριθμητική τιμή, δηλαδή στον μέσο όρο της μη γραμμικής συνάρτησης.



Παρατηρούμε ότι το αποτέλεσμα είναι ίδιο με την κανονική pca.

β)

Σε αντίθεση με την κανονική pca, κάνουμε έναν εκθετικό υπολογισμό της απόστασης (norm) κάθε δείγματος από το μηδέν και καταλήγουμε σε μία μόνο τιμή. Επομένως, το μητρώο συνδιασποράς δεν μπορεί παρά να είναι ένας βαθμωτός (μονοδιάστατος) όρος, που αποτυπώνει πόσο απλωμένες είναι αυτές οι τιμές $\exp(-\frac{\|x_m\|^2}{0.1})$ γύρω από τον μέσο όρο τους.


```
Digit 0 παραδείγματα: 5923
Digit 1 παραδείγματα: 6742
Συνολικό μέγεθος N = 12665
Σχήμα k_values: (12665,)
Σχήμα του μητρώου συνδιασποράς: (1, 1)
Μητρώο συνδιασποράς = [[1.61178803e-115]]
Διακύμανση των k(x): 0.000000
```

Από τα αποτελέσματα, κατανοούμε ότι σε αντίθεση με την κανονική pca που έχει μεγάλη διακύμανση αφού έχει 784 γραμμικά χαρακτηριστικά, τώρα έχουμε μηδενική αφού έχουμε βαθμωτο.


γ)

Στη PCA, κάθε κύρια συνιστώσα είναι ένα διάνυσμα 784 διαστάσεων και αναπαρίσταται εύκολα ως θολή εικόνα, αφού οι άξονες μέγιστης διασποράς καθορίζονται γραμμικά στον αρχικό χώρο των pixels. Αντίθετα, στην kernel PCA

οι συνιστώσες ορίζονται σε έναν μη γραμμικό χώρο πολύ υψηλότερης (ή και άπειρης) διάστασης. Έτσι, δεν προκύπτουν άμεσα τέτοιες εικονο-μορφές για κάθε συνιστώσα.




δ)



Παρατηρούμε ότι η εικόνα βελτιώνεται ελάχιστα σε ποιότητα ακόμη και με τα αυξημένα επίπεδα, σε αντίθεση με τα θετικά αποτελέσματα της απλής Pca.


ε)



Autoencoders

Διαδικασία 1

Η θεωρία λέει πως ένας autoencoder χωρίς bias και με γραμμικές ενεργοποιήσεις, που ελαχιστοποιεί το μέσο τετραγωνικό σφάλμα, οδηγείται αλγεβρικά στα ίδια ιδιοδιανύσματα με την κλασική PCA. Εδώ όμως χρησιμοποιούμε τη δυαδική εντροπία, η οποία στοχεύει στην καλύτερη πιθανοτική προσέγγιση των εισόδων ως τιμές 0 ή 1 (πιθανότητες), και όχι στην ανάλυση μέγιστης διασποράς που επιτυγχάνει η PCA. Επιπλέον, η έξοδος του δικτύου περιορίζεται στο $[0,1]$ λόγω της συνάρτησης sigmoid, κάτι που συγκρούεται με τα κεντραρισμένα δεδομένα όπου αρκετές τιμές των pixels είναι αρνητικές. Το δίκτυο, στην προσπάθειά του να ελαχιστοποιήσει τη δυαδική εντροπία, μαθαίνει βάρη τα οποία είναι βέλτιστα ως προς αυτό το κριτήριο κι όχι απαραίτητα κατάλληλα για την καταγραφή της μέγιστης διασποράς, όπως κάνει η PCA. Έτσι, οι στήλες του πίνακα βαρών στον κωδικοποιητή απομακρύνονται από τις κύριες συνιστώσες του χώρου και η ομοιότητα με το VL μηδενίζεται.



Διαδικασία 2

Ορίζουμε έναν μη γραμμικό κωδικοποιητή (encoder) 3 επιπέδων: $784 \rightarrow 512 \rightarrow 256 \rightarrow 128$ με ενεργοποιήσεις leaky-ReLU, και αντίστοιχα έναν μη γραμμικό αποκωδικοποιητή (decoder) 3 επιπέδων: $128 \rightarrow 256 \rightarrow 512 \rightarrow 784$ με leaky-ReLU στα ενδιάμεσα ώστε να μην απορρίπτονται οι αρνητικές τιμές και ελεύθερη έξοδο. Μετά την `summary()` του μοντέλου (που εμφανίζει το πλέγμα των επιπέδων και τον αριθμό παραμέτρων), γίνεται `compile` με `optimizer Adam` και κόστος `Mse`. Εκπαιδεύουμε για 40 εποχές με `batch_size 250`, όπως στο προηγούμενο ερώτημα.

Υπολογιζόμενος αριθμός trainable παραμέτρων: 1132944

Διαδικασία 3

α)

Ένας τρόπος να μειώσουμε στο μισό τις παραμέτρους ενός πλήρως συνδεδεμένου autoencoder και παράλληλα να διατηρήσουμε τη λογική της PCA, είναι να χρησιμοποιήσουμε το ίδιο μητρώο βαρών (tied weights) στον αποκωδικοποιητή και τον κωδικοποιητή, αλλά με μεταφορά (transpose) αντί να ορίσουμε ξεχωριστές παραμέτρους για κάθε μέρος. Με άλλα λόγια, ο αποκωδικοποιητής εφαρμόζει ουσιαστικά την αντίστροφη πράξη του κωδικοποιητή, χρησιμοποιώντας ακριβώς τους ίδιους πίνακες βαρών, ώστε το δίκτυο να παραμένει συμμετρικό ως προς τα δύο τμήματά του.

β)

Εφόσον επιδιώκουμε να διατηρήσουμε τη συμμετρία της όλης αρχιτεκτονικής (ώστε ο αποκωδικοποιητής να λειτουργεί ως καθρέφτης του κωδικοποιητή), πρέπει να χρησιμοποιήσουμε και στον αποκωδικοποιητή τις ίδιες ακριβώς ενεργοποιήσεις leaky ReLU με κλίση 0.2. Ο λόγος είναι ότι, στην προσέγγιση tied weights και γενικότερα στη λογική της αντίστροφης διαδικασίας, δεν πρέπει να αλλάζει η συνάρτηση που εφαρμόζεται σε κάθε κλάδο του δικτύου. Αν βάζαμε, σκέτη ReLU, θα σπάγαμε τη συμμετρία και δεν θα είχαμε πλέον την ίδια μη γραμμική πράξη στον αποκωδικοποιητή, γεγονός που θα αναιρούσε την αναμενόμενη αντιστοίχιση με τη λογική της PCA.

Συνολικές trainable παράμετροι (tied AE): 233472


Διαδικασία 4

Trainable Παράμετροι (pseudo-isotropic AE): 233472


Η κεντρική ιδέα είναι ότι, αντί να ορίσουμε νέο σετ βαρών για τον αποκωδικοποιητή (που θα διπλασίαζε τον αριθμό των παραμέτρων), βασιζόμαστε αποκλειστικά σε μια ορθοκανονικοποιημένη εκδοχή των βαρών του κωδικοποιητή. Έτσι, ο αποκωδικοποιητής δεν διαθέτει δικά του trainable weights, αλλά εφαρμόζει στους λανθάνοντες κώδικες (latent codes) ένα ψευδο-νισότροπο φίλτρο, το οποίο υπολογίζεται μία φορά μέσω της ανάλυσης SVD των βαρών του κωδικοποιητή. Αυτό σημαίνει ότι ο συνολικός αριθμός βαρών που μαθαίνει το δίκτυο (trainable parameters) περιορίζεται ουσιαστικά στο μισό, καθώς δεν υπάρχουν ξεχωριστοί πίνακες στον αποκωδικοποιητή. Στην πράξη, το σκεπτικό διαφέρει ελάχιστα από την μέθοδο tied weights, όπου ο αποκωδικοποιητής χρησιμοποιεί τη μεταφορά W_{enc}^T . Στην ψευδο-νισότροπη περίπτωση, αντί να πάρουμε αυτούσια τη μεταφορά του πίνακα του κωδικοποιητή, χρησιμοποιούμε SVD και δημιουργούμε ένα ορθοκανονικο μητρώο.

Διαδικασία 5


Γραμμικός autoencoder:



Μη Γραμμικός autoencoder:



Tied weights autoencoder:



Πιθανοτική PCA

Απόδειξη 1

Πρώτα, θυμόμαστε ότι στο μοντέλο της πιθανοτικής PCA εισάγουμε μια μεταβλητή Z διαστάσεων L . Αυτή έχει κατανομή $N(0, I)$, δηλαδή μέση τιμή ίση με το μηδενικό διάνυσμα και μοναδιαίο πίνακα συνδιασποράς. Ορίζουμε επιπλέον ένα μητρώο βαρών W , διαστάσεων $N \times L$ και ένα διάνυσμα μετατόπισης μ διαστάσεων $N \times 1$. Στο πλαίσιο του γεννητικού μοντέλου, θεωρούμε επίσης έναν θόρυβο ε , ο οποίος ακολουθεί πολυδιάστατη κανονική κατανομή με μηδενική μέση τιμή και συνδιασπορά $\sigma^2 I$. Παρακάτω, ορίζουμε το παρατηρούμενο X βάσει της σχέσης $X = WZ + \mu + \varepsilon$ και θέλουμε να βρούμε την αναμενόμενη τιμή του X . Θυμόμαστε ότι η αναμενόμενη τιμή ενός αθροίσματος τυχαίων μεταβλητών ισούται με το άθροισμα των αναμενόμενων τιμών τους. Ταυτόχρονα, το μ και το W δεν είναι τυχαία μεγέθη, άρα εισέρχονται ως σταθεροί παράγοντες. Συγκεκριμένα, ο όρος WZ έχει μέση τιμή ίση με $WxE\{Z\}$. Επειδή Z ορίστηκε ως $N(0, I)$, γνωρίζουμε ότι $E\{Z\}=0$. Επομένως ο πρώτος όρος WZ συνεισφέρει μηδέν στην αναμενόμενη τιμή. Ο θόρυβος ε έχει επίσης μηδενική μέση τιμή, συνεπώς και ο όρος ε συνεισφέρει μηδέν. Έτσι, παραμένει μόνο το σταθερό διάνυσμα μ . Ως εκ τούτου, $E\{X\} = E\{WZ\} + E\{\mu\} + E\{\varepsilon\} = 0 + \mu + 0 = \mu$.

Παρακάτω, η συνδιασπορά του X ορίζεται ως $\Sigma_{XX} = EX - E\{X\}^T$. Από το προηγούμενο βήμα γνωρίζουμε ότι $E\{X\} = \mu$. Άρα, αρκεί να δούμε τι προκύπτει αν στο $X - \mu$ υποκαταστήσουμε τους όρους του μοντέλου $X - \mu = (W + \mu + \varepsilon) - \mu = WZ + \varepsilon$. Η ποσότητα της οποίας τη συνδιασπορά θέλουμε είναι λοιπόν $WZ + \varepsilon$. Αυτός υπολογίζεται παίρνοντας την αναμενόμενη τιμή του $(WZ + \varepsilon)(WZ + \varepsilon)^T$. Εδώ προκύπτουν τέσσερις όροι, όπου οι δυο έχουν μηδενική μέση τιμή. Άρα αθροίζοντας τους παίρνουμε τελικά την σχέση που ψάχνουμε.

Απόδειξη 2

Ξεκινάμε με το γραμμικό-Γκαουσιανό μοντέλο του πιθανοτικού PCA, στο οποίο η λανθάνουσα μεταβλητή Z ακολουθεί την κανονική κατανομή $N(0, I)$. Για κάθε συγκεκριμένη τιμή $Z=z$, η παρατήρηση $X=x$ παράγεται από την Gaussian $N(Wz + \mu, \sigma^2 I)$. Σύμφωνα με το θεώρημα του Bayes, η εκ των υστέρων πυκνότητα της Z υπό συνθήκη $X=x$ είναι $f_Z|X(x) = \frac{f(X|Z)(X|Z)f_Z(Z)}{f_X(x)}$. Συνεπώς, η εκ των υστέρων μέση τιμή εξαρτάται από το x , ενώ η εκ των υστέρων συνδιασπορά $\sigma^2 \Sigma_1^{-1}$ είναι σταθερή για κάθε x .

Kullback-Leibler Divergence

Απόδειξη 1

Το Kullback-Leibler Divergence (KLD) μετράει πόσο διαφορετική είναι μια κατανομή p από μια υποθετική κατανομή q . Ορίζεται ως $D_{KL}(p||q) = \int p(x) \log \frac{p(x)}{q(x)} dx$ και εκφράζει την πρόσθετη πληροφορία που απαιτείται για την περιγραφή μιας μεταβλητής, όταν θεωρούμε ότι προέρχεται από το q αντί για την πραγματική p . Το KLD δεν είναι συμμετρικό, δηλαδή $D_{KL}(p||q)$ συνήθως διαφέρει από το $D_{KL}(q||p)$. Κεντρικό αποτέλεσμα είναι ότι το $D_{KL}(p||q)$ είναι πάντα μη αρνητικό, με ισότητα αν και μόνο αν $p(x)=q(x)$.

Απόδειξη 2

Για να ελέγξουμε αν οι τυχαίες μεταβλητές X και Y είναι ανεξάρτητες, συγκρίνουμε την κοινή κατανομή $f_{X,Y}(x,y)$ με το γινόμενο των περιθωριακών f_X και f_Y . Αν X και Y είναι ανεξάρτητες, τότε το KLD μηδενίζεται. Η ποσότητα αυτή ταυτίζεται με την αμοιβαία πληροφορία (mutual information), η οποία αποτελεί μη αρνητικό μέτρο και μηδενίζεται μόνο σε περίπτωση ανεξαρτησίας.


Variational Autoencoders

Διαδικασία 1


α)

Οι εικόνες που εμφανίζονται στο παραγόμενο 4×4 πλέγμα (στις εποχές 1, 50 και 100) δείχνουν πώς εξελίσσεται η γενετική ικανότητα του Variational Autoencoder με τη σταδιακή εκπαίδευση. Στην αρχή (Epoch 1), οι εικόνες δεν είναι ευδιάκριτες αλλά βλέπουμε μόνο κάποια θολά περιγράμματα. Όσο προχωράμε προς την Epoch 50, τα ψηφία γίνονται πιο καθαρά, ενώ στην Epoch 100 έχει βελτιωθεί σημαντικά η οπτική ποιότητα και η συνολική ομοιότητα με τα αρχικά γράμματα. Η βελτίωση οφείλεται στη σταδιακή προσαρμογή των δύο όρων στο κόστος, δηλαδή ο όρος ανακατασκευής (binary crossentropy) μαθαίνει να απεικονίζει πιστά τα pixel, ενώ ο όρος Kullback-Leibler Divergence μετακινεί την κατανομή των λανθανουσών μεταβλητών προς την $N(0, I)$. Με άλλα λόγια, το VAE σταδιακά γεμίζει τον λανθάνοντα χώρο κατά τρόπο που η κωδικοποιημένη πληροφορία να αρκεί για την αναγέννηση ψηφίων, ενώ ταυτόχρονα παραμένει αρκετά ομαλός ώστε οποιοδήποτε σημείο εκεί (π.χ. ένα τυχαίο z) να οδηγεί σε έγκυρη εικόνα ψηφίου.


Epoch 1 - Generated from $N(0, I)$




Epoch 50 - Generated from $N(0, I)$



Epoch 100 - Generated from $N(0, I)$



β)



Η παραπάνω εικόνα δείχνει πώς ο κωδικοποιητής του VAE χαρτογραφεί τα δεδομένα ελέγχου σε έναν δισδιάστατο λανθάνοντα χώρο, δηλαδή κάθε σημείο είναι η μέση τιμή μ που αντιστοιχεί σε ένα ψηφίο και το χρώμα δείχνει την τάξη του ψηφίου. Παρατηρούμε ότι τα ίδια ψηφία συγκεντρώνονται κατά προσέγγιση σε επιμέρους περιοχές, χωρίς όμως να διαχωρίζονται απόλυτα. Αυτό συμβαίνει επειδή ο VAE επιδιώκει να αναπαριστά πιστά τα δεδομένα (reconstruction) και να διαμορφώνει τον λανθάνοντα χώρο ώστε να ταιριάζει σε μια κανονική κατανομή $N(0, I)$. Έτσι, κάθε ψηφίο καταλήγει να καλύπτει μια συνεχή ζώνη στον χώρο, ώστε κάθε σημείο z να οδηγεί σε μια έγκυρη έξοδο, ακόμη κι αν δεν υπάρχει αυστηρός διαχωρισμός των κλάσεων.